

Conversion HFR LFR

Florent GUIOTTE¹, Paul LE DENN¹, Briec DANIEL¹, Danchi LI¹

Olivier LE MEUR²

Jean-Yves AUBIE³

Résumé

Le monde de la vidéo a vu naître de nombreux formats durant ces dernières années. Les technologies ont rapidement évolué et nous permettent de visionner des vidéos en HD, Full HD et même Ultra HD. De la même manière, les caméras permettent de filmer des séquences vidéo HFR avec un rythme d'image de l'ordre de 100 images par seconde — plus fluides que des vidéos LFR — 50 images par secondes. Malheureusement, tous les écrans ne sont pas en mesure d'afficher des vidéos enregistrées à de telles fréquences. Nous travaillons en partenariat avec b<>com pour effectuer la conversion d'une fréquence élevée vers une fréquence adaptée, afin d'obtenir des vidéos compatibles pour tous les écrans. Une vidéo HFR contient des images plus nettes qu'une vidéo LFR, supprimer une image sur deux provoquerait donc des saccades désagréables à l'œil. Nous proposons dans notre solution une approche perfectionnée prenant en compte l'effet de flou provoqué par des objets en mouvement. Cet effet est naturellement présent dans les vidéos LFR et est appelé flou de mouvement ou flou cinétique. Nous détectons le mouvement dans la vidéo via le calcul d'un flot optique et d'un gradient temporel, puis nous appliquons un traitement pour reproduire le flou cinétique selon le mouvement.

The world of video has produced many formats in recent years. Technology has advanced rapidly and allow us to watch videos in HD, Full HD and even Ultra HD. Similarly, the cameras used to record HFR videos with an image rate of about 100 frames per second — more fluid than LFR video — 50 frames per second. Unfortunately, all the screens are not able to display these videos recorded at such frequencies. We partner with b<>com to convert a high frequency to a suitable frequency, in order to get compatible videos for all screens. A video contains sharper HFR images than LFR video, delete an image on two jerks therefore cause unpleasant to the eye. We offer our solution in a sophisticated approach taking into account the blur caused by moving objects. This effect is naturally present in LFR and videos is called motion blur. We detect motion in the video through calculating an optical flow and a temporal gradient, then apply a treatment to reproduce the motion blur according to the movement.

Mots-Clés

Haute fréquence d'image (High Frame Rate, HFR), faible fréquence d'image (Low Frame Rate, LFR), flot optique, conversion

¹Imagerie Numérique, École Supérieure d'Ingénieurs de Rennes, Université de Rennes 1, France

²École Supérieure d'Ingénieurs de Rennes, Université de Rennes 1, France

³b<>com, Rennes, France

Table des matières

	2 Résultats et Discussion	4
	2.1 Phase d'annonce	4
	2.2 Les clés de lecture	4
	Pas d'analyse	
	3 Conclusion	4
	3.1 Présentation/interprétation des résultats et limite	4
	3.2 ouverture	4
	Remerciements	4
Introduction	2	
1 Méthodes	2	
1.1 Les méthodes utilisées	2	
La décimation simple • La pondération simple • La double pondération • Gradient spatio temporel		
1.2 Avantage et contraintes des méthodes	3	
La décimation simple • La pondération simple • La double pondération • Gradient spatio-temporel		
1.3 Pourquoi les méthodes choisies permettent de répondre à la problématique	4	
La décimation et les pondérations		

Introduction

Les entreprises évoluant dans le domaine du traitement d'image et de la compression vidéo cherchent à développer de nouveaux formats permettant un gain de qualité. Pour cela, deux paramètres peuvent être améliorés : la qualité spatiale (résolution d'image, compression) et temporelle (haute fréquence d'image). Ces deux paramètres sont l'objet de travaux au sein de l'institut de recherche technologique b<>com qui a pour objectif de fournir une meilleure sensation d'immersion des spectateurs dans les contenus audiovisuels. Cet institut de recherche possède un laboratoire étudiant le réalisme des contenus. Leur but est de développer des outils visant à faciliter la prise en main de ces futurs formats par les professionnels du secteur (cinéma, télévision, jeux, publicité, etc.) et, à terme, par le public. Parallèlement, les chercheurs de b<>com travaillent sur la possibilité de rendre ces formats lisibles sur des moniteurs non compatibles. C'est notamment le cas des vidéos enregistrées à une fréquence d'images élevées, typiquement 100 ou 120 images par seconde (ips), non lisibles sur des écrans qui ne peuvent afficher que 50 ou 60 ips maximum. Dans cette optique, nous sommes amenés à proposer une solution permettant de réduire de moitié la fréquence d'image de vidéos HFR sans détériorer la fluidité des mouvements pour le spectateur. En HFR, l'intervalle de temps entre 2 images consécutives est très court, les déplacements des objets entre les 2 images le sont donc également. La succession des images donne alors une impression de mouvement très proche de la réalité. En LFR, cet intervalle de temps étant plus important, la fluidité est obtenue par un rendu plus flou des objets en mouvements (figure 1). Il s'agit du flou cinétique, provoqué par le temps de pose plus long de la caméra lors de la capture d'une image. Pour réduire la fréquence d'image, la solution intuitive consisterait à supprimer une image sur deux. Néanmoins, des travaux réalisés auparavant à b<>com ont montré que cette solution n'est pas satisfaisante car elle ne permet pas de retrouver le flou cinétique. La vidéo semble alors très hachée. De même, des traitements globaux comme une combinaison linéaire classique d'images successives n'élimine pas suffisamment les saccades. Dans ce document, nous étudions la manière dont il est possible de simuler le flou cinétique localement sur les images. Les deux solutions que nous proposons se basent sur l'estimation du mouvement dans la vidéo originale. La première consiste à reprendre l'idée d'une combinaison de plusieurs images, cette fois avec une accélération matérielle. La seconde méthode est l'application de flous cinétiques sur les objets qui se déplacent grâce à des gradient temporels.

1. Méthodes

1.1 Les méthodes utilisées

1.1.1 La décimation simple

Ici le but est très naïf, il s'agit simplement de supprimer du flux initial une image sur deux et ainsi passer d'un contenu ayant 120 images par seconde à un contenu n'en possédant

que 60.

Ce qui a l'avantage d'être le plus rapide à l'exécution mais en contrepartie aucun traitement n'est effectué comme du flou de mouvements.

1.1.2 La pondération simple

La pondération simple est le fait de se baser deux images consécutives pour en créer une nouvelle, on s'appuie sur la somme pondérée de deux tableaux multidimensionnels (les canaux étant traités séparément) représentant les deux images en entrée pour ensuite avoir un résultat pondéré à cinquante pour-cent de chaque image.

Ceci a l'avantage de bien représenter la continuité spatiale de deux images proches en plus de diminuer par deux le flux d'images initial.

1.1.3 La double pondération

La double pondération quand à elle se base sur trois images consécutives afin de créer notre nouvelle image, ici on s'appuie sur trois sommes pondérées consécutives entre, respectivement, notre image courante et notre image précédente, notre image courante et notre image suivante et finalement la somme pondérée entre ces deux résultats précédents.

Ceci a l'avantage de mieux représenter la continuité spatiale d'images proches en plus de, elle aussi, diminuer par deux le flux d'images initial. Mais elle ne prend pas en compte la compensation de mouvements malheureusement.

1.1.4 Gradient spatio temporel

L'une des méthode testée pour générer du flou de mouvement est l'approximation du flot optique à l'aide d'un gradient spatio temporel. Cette solution se veut peu coûteuse en calcul, contrairement à la méthode proposée l'année dernière qui cherche à déterminer précisément le flot optique.

En prenant un flux vidéo, le principe est de générer un gradient en prenant en compte l'image précédente et l'image suivante en plus de la prise en compte du spatiale d'un gradient classique, d'où la notion temporel.

Pour la suite de l'explication de la méthode, nous utilisons les notations suivantes :

- I : la vidéo, une succession d'image
- $I(x, y, t)$: le pixel de coordonnée (x, y) de l'image t de la vidéo
- G : le gradient

Soit $I : \Omega \in \mathbb{R}^3 \rightarrow \mathbb{R}^3$, soit $G : \Omega \in \mathbb{R}^3 \rightarrow \mathbb{R}^2$.

$G(x, y, t)$ représente le vecteur gradient associé au pixel de coordonnée (x, y) de l'image t . Le fait de faire varier t permet directement de prendre en compte le temps. On décompose le gradient dans les deux directions :

$$G(x, y, t) = \begin{cases} G_x(x, y, t) \\ G_y(x, y, t) \end{cases}$$

Où G_x représente le gradient en x et G_y le gradient en y , semblable à un gradient classique, ce qui permet de prendre en compte l'espace.

Par soucis de lisibilité, on utilise t pour symboliser l'emplacement relatif dans le flux d'image, où t_0 représente donc l'image actuelle, t_{-1} l'image précédente et t_{+1} l'image suivante.

Dans un premier temps, on utilise un calcul simple du gradient :

$$\begin{cases} G_x(x, y, t_0) = I(x^{-1}, y, t_{-1}) - I(x^{+1}, y, t_{+1}) \\ G_y(x, y, t_0) = I(x, y^{-1}, t_{-1}) - I(x, y^{+1}, t_{+1}) \end{cases}$$

où on effectue une différence entre le pixel précédent en x ou y entre l'image suivante et l'image précédente. On obtient les contours des objets et des zones de mouvements.

Dans un deuxième temps, afin de d'augmenter la robustesse de cet opérateur de gradient, notre solution implémente un filtre de Sobel adapté à notre utilisation temporel. Le filtre de Sobel par rapport à la première solution a un rôle de filtre passe bas pour limiter l'influence du bruit contenu dans la séquence vidéo sur notre estimation de mouvement :

$$\begin{cases} G_x(x, y, t_0) = \dots \\ G_y(x, y, t_0) = \begin{bmatrix} I(x^{-1}, y^{-1}, t_{-1}) & 0 & I(x^{-1}, y^{+1}, t_{+1}) \\ 2 \times I(x, y^{-1}, t_{-1}) & 0 & 2 \times I(x, y^{+1}, t_{+1}) \\ I(x^{+1}, y^{-1}, t_{-1}) & 0 & I(x^{+1}, y^{+1}, t_{+1}) \end{bmatrix} \end{cases}$$

On calcul le tenseur de structure associé à notre gradient précédemment obtenus tel que :

$$T(x, y, t_0) = \begin{bmatrix} G_x(x, y, t_0)^2 & G_x(x, y, t_0)G_y(x, y, t_0) \\ G_y(x, y, t_0)G_x(x, y, t_0) & G_y(x, y, t_0)^2 \end{bmatrix}$$

Les vecteurs propres et les valeurs propres de ce tenseur permettent d'obtenir rapidement la direction normale au gradient et la norme du gradient. Par extension, la direction du déplacement et sa vitesse.

Concernant la direction normale au gradient, on peut l'obtenir avec cette relation :

$$\Theta^+ = \begin{bmatrix} 2 \times T(x, y, t_0)_{1,2} \\ T(x, y, t_0)_{2,2} - T(x, y, t_0)_{1,1} + \sqrt{\Delta} \end{bmatrix}$$

Où :

$$\Delta = (T(x, y, t_0)_{1,1} - T(x, y, t_0)_{2,2})^2 + 4T(x, y, t_0)_{1,2}^2$$

Et pour obtenir la norme du gradient :

$$C = \left(\frac{\lambda_+ - \lambda_-}{\lambda_+ + \lambda_-} \right)$$

Où :

$$\lambda_{\pm} = \frac{T(x, y, t_0)_{1,1} + T(x, y, t_0)_{2,2} \pm \sqrt{\Delta}}{2}$$

La combinaison de la normale au gradient et sa norme intégrée à l'image entière nous donne un champ dense de vecteurs, ou le flux optique.

Pour visualiser ce flux optique, nous avons converti ces données en image *Hue*, *Saturation*, *Lightness* (HSL) :

- La direction est traduite en couleur sur le disque du Hue
- La norme est exprimée en luminosité

Un exemple de cette visualisation par image HSL est visible figure 1.




FIGURE 1. Mouvements visualisé avec une image HSL

Une fois les mouvements détectés et exprimés pour chaque pixel, nous utilisons ces informations pour recréer un flou de mouvement pour augmenter la sensation de fluidité de la vidéo. Afin de réaliser cette illusion nous appliquons un flou directionnel sur chaque pixel de l'image en pondérant sa valeurs avec ses voisins en fonction de la direction et de la taille de la norme.

1.2 Avantage et contraintes des méthodes

1.2.1 La décimation simple

Les avantages substantiels de cette méthode sont : son temps d'exécution et sa simplicité. En effet, elle ne requiert guère plus de temps que l'ouverture du flux vidéo, le parcours d'une image sur deux et la fermeture du dit flux. Ce qui lui permet d'être très rapide mais en contre partie on doit payer le coût de n'effectuer aucun traitement sur les images ce qui peut provoquer une gêne à l'utilisateur lors de la visualisation de la séquence finale.

1.2.2 La pondération simple

La pondération simple requiert un temps d'exécution plus long mais cela reste modeste pour un traitement sur des vidéos dites « FullHD » c'est à dire de résolution 1920x1080 pixels. Elle a pour avantage de pondérer deux images proches temporellement et donc possiblement spatialement en plus de diminuer elle aussi le nombre d'images en sortie afin de pouvoir conserver une flux dit à 60 images par seconde.

Cependant cette méthode à faible coût ne prend en compte que la cohérence temporelle et ne cherche pas à recréer un vrai contenu natif 60 Hertz donc ne recrée pas de flou de mouvements. Le problème des saccades reste donc encore présent dans les vidéos de résultats.

1.2.3 La double pondération

Cette dernière technique de pondération repose sur un calcul à partir de 3 images consécutives. Elle a l'avantage de mieux prendre en compte le déplacement dans une scène grâce à la connaissance de l'image d'avant et celle d'après et réduit l'effet de saccades.

Mais elle ne prend toujours pas en compte la particularité du flou de mouvements des contenus à 60 images par seconde ni des vecteurs de déplacement entre deux images consécutives.

1.2.4 Gradient spatio-temporel

Cette méthode est relativement plus coûteuse que les pondérations. En contre partie, elle s'appuie sur l'approximation du flux optique des images pour recréer un flou de mouvement plus réaliste en prenant en compte la direction et la vitesse du mouvement.

L'estimation du mouvement est par contre approximative, contrairement à un algorithme de type *Patch Match*. Elle peut être mauvaise quand les mouvements sont de trop grande amplitude pour que les informations soient contenues dans le gradient spatio temporel (rappel : le gradient se base uniquement sur le pixel voisin de la frame précédente ou suivante). Malgré ce désavantage, cette technique propose un bon compromis entre les méthodes de pondération naïves et les méthodes précises mais très coûteuses basées sur *Patch Match*.

1.3 Pourquoi les méthodes choisies permettent de répondre à la problématique

1.3.1 La décimation et les pondérations

Ces méthodes dites « Low Cost » permettent de répondre à la problématique car elles effectuent une décimation du nombre d'images dans la vidéo, ces traitements sont qualifiés de rapide compte tenu du type de séquences proposées en entrée. Il sera explicité dans la partie discussion que les vidéos obtenus avec ces méthodes donnent de bons résultats sur un public non averti.

2. Résultats et Discussion

TODO Tableau

2.1 Phase d'annonce

2.2 Les clés de lecture

2.2.1 Pas d'analyse

3. Conclusion

La problématique initiale de notre projet s'articulait autour des moyens possibles afin de pouvoir passer d'une vidéo de très haute qualité avec une cadence de 120 images par secondes (FullHD/4K 120IPS) à un contenu adapté pour d'anciennes générations de téléviseurs ou d'appareils mobiles ne permettant que d'afficher 60 images par secondes.

Nous devons développer des techniques aussi bien frugales telles qu'une simple décimation ou de la pondération, que plus gourmandes en termes de calculs et de temps d'exécution

comme le gradient temporel ou plus rapides grâce à l'implémentation de calculs sur des processeurs de carte graphique.

3.1 Présentation/interprétation des résultats et limite TODO

3.2 ouverture

Néanmoins il reste énormément de travail sur ce sujet si l'on veut un jour pouvoir efficacement adapter ce genre de contenu à la volée, les méthodes proposées actuellement à b<>com cherchent juste à émuler un contenu 60Hz à partir d'une source à 120Hz. Elles ne représentent pas réellement une vraie vidéo enregistrée à une cadence d'image de 60Hz. C'est pour cela qu'il reste du travail à faire en terme de développement technique afin de se rapprocher le plus possible d'un contenu natif, légitime et authentique à 60Hz.

Remerciements

Nous voudrions remercier M. Jean-Yves AUBIE pour son indéfectible soutien ainsi que pour son temps mis à notre disposition lors des tests effectués à b<>com.

M. Olivier LE MEUR pour son aide apportée tout du long du projet et son temps passé avec nous.